

Documentação Técnica

Sistema de Auditoria de Ligações — arquitetura, fluxo, código e telas.

Versão do sistema documentada: 1.3.203

Data de referência: 2026-06-24

Sumário

- 0. Sobre este documento
 - 0.1 Como ler
 - 0.2 Documentos relacionados
- 1. Objetivo e escopo
 - 1.1 Objetivo
 - 1.2 Escopo
 - 1.3 Princípio central: a esteira binária
- 2. Termos e definições
- 3. Visão geral do sistema
 - 3.1 O que o sistema faz, em seis passos
 - 3.2 O caminho de uma ligação, do início ao fim
 - 3.3 Três observações que evitam diagnósticos errados
 - 3.4 A pilha de tecnologia, em uma linha
- 4. Papéis e responsabilidades
 - 4.1 Perfis de uso
 - 4.2 A autoridade de auditoria
- 5. Arquitetura e componentes
 - 5.1 Visão de alto nível
 - 5.2 Backend, por subsistema
 - 5.3 Frontend, por feature
 - 5.4 As camadas de dados
 - 5.5 O que é legado (não usar como referência)
 - 5.6 Decisões de arquitetura registradas
- 6. Fluxo operacional do dia a dia
 - 6.1 O ciclo diário
 - 6.2 A coleta e os filtros — onde o volume "encolhe"
 - 6.3 O teto por operador — e por que ele foi separado da cota
 - 6.4 Quantas baixar: a "Meta" e o teto de segurança
 - 6.5 O funil com números reais
 - 6.6 A classificação
 - 6.7 Endpoints de diagnóstico (operação)
 - 6.8 Agendamento (cron) — como ligar o ciclo diário
- 7. Regras de negócio e critérios
 - 7.1 A cota de envio ao supervisor (2 por operador/mês)
 - 7.2 Direção da chamada
 - 7.3 Setores e apelidos
 - 7.4 O catálogo de critérios
 - 7.5 A nota e a zeragem
- ... a zeragem por critério fatal em 3 camadas

(criterionId determinístico → fatal_flags da IA → fallback por substring),
respeitando o fallback legítimo de CPF quando o motorista confirma não ter senha.

8. Segurança e proteção de dados

8.1 Acesso e papéis

8.2 Rede

8.3 Segredos

8.4 Proteção de dados (LGPD)

8.5 O dado de produção é protegido contra a suíte de testes

9. Custos e contingência

9.1 Onde há custo

9.2 Proteções de custo (guardrails)

9.3 Contingência

10. Indicadores e rastreabilidade

10.1 O que é medido

10.2 Rastreabilidade (trilha de auditoria do próprio sistema)

10.3 Onde acompanhar no dia a dia

11. Configurações do sistema

11.1 As duas configurações que controlam o volume

11.2 Referência completa de variáveis

12. Referências

Anexo A — Histórico de versões

Anexo B — Guia das telas (interface)

B.1 Triagem — a porta de entrada (rota /classifier)

B.2 Auditoria manual — três passos (rota /audit)

B.3 Arquivos Salvos — o gate humano (rota /salvos)

B.4 Automação — o painel do ciclo (rota /automacao)

B.5 Colaboradores — o cadastro que controla o sync (rota /colaboradores)

0. Sobre este documento

Documentação técnica do sistema de auditoria de qualidade de ligações: o que cada componente faz, como o fluxo funciona de ponta a ponta e onde isso está no código. Serve de referência para entender, operar e manter o sistema.

Item	Valor
Versão do sistema documentada	1.3.203
Data de referência	2026-06-24
Idioma	Português (Brasil)

O histórico de mudanças do sistema fica em `logs/versions/x.y.z.md` — uma entrada por versão.

0.1 Como ler

Documento autocontido: pode ser lido sem abrir outros arquivos. Combina três níveis de leitura:

1. **Explicação** do que cada parte faz e por quê, sem exigir conhecimento de programação.
2. **Trecho de código real**, sempre com a referência `arquivo:linha` de onde foi extraído. O código é reproduzido como está no repositório; quando encurtado, o corte é sinalizado com `...`. É a parte para quem quer ver como funciona por dentro — pode ser pulada sem perda do entendimento geral.
3. **Telas** — esboço fiel da interface (com os rótulos reais) e a explicação de cada controle.

0.2 Documentos relacionados

Este documento reúne a documentação técnica do repositório. Para o detalhe vivo e sempre atualizado de cada tema, as fontes são:

Tema	Fonte no repositório
Índice da documentação técnica	<code>docs/README.md</code>
Visão de negócio	<code>docs/01-visao-geral.md</code>
Mapa do código	<code>docs/02-arquitetura.md</code>
Schema do banco de dados	<code>docs/03-banco-de-dados.md</code>
Variáveis de ambiente	<code>docs/04-variaveis-de-ambiente.md</code> e <code>backend/.env.example</code>
Operação e diagnóstico	<code>docs/05-operacao-runbook.md</code>
Integração Huawei	<code>docs/06-integracao-huawei.md</code>
Custos e proteções	<code>docs/07-custos-e-guardrails.md</code>
Segurança	<code>docs/08-seguranca.md</code>
Testes	<code>docs/09-testes.md</code>
Histórico de mudanças	<code>logs/versions/x.y.z.md</code>

1. Objetivo e escopo

1.1 Objetivo

O sistema tem um objetivo único: **medir e garantir a qualidade do atendimento telefônico** da operação, de forma padronizada, rastreável e com o mínimo de trabalho manual. Ele ouve as ligações, transcreve, compara o atendimento com os critérios oficiais de qualidade e produz uma nota com justificativa por critério — o que antes dependia de um auditor ouvir ligação por ligação.

A inteligência artificial faz o trabalho pesado (transcrever e avaliar), mas a **palavra final é humana**: nenhuma auditoria chega ao supervisor sem passar pela revisão de um auditor.

1.2 Escopo

Está dentro do escopo deste sistema:

- Coletar automaticamente as gravações do dia anterior na telefonia Huawei AICC.
- Receber áudio ou documento (PDF de chat) por envio manual.
- Selecionar o que vale a pena auditar, aplicando regras de negócio e uma triagem assistida por IA.
- Classificar cada ligação (setor, alerta, operador).
- Transcrever o áudio e avaliar a ligação contra o catálogo oficial de critérios.
- Submeter toda auditoria a um gate humano antes do envio ao supervisor.
- Encaminhar o fluxo de aprovação/contestação e consolidar o fechamento mensal.

Está **fora** do escopo:

- O sistema não substitui o julgamento do auditor — ele prepara e organiza o material; a decisão de enviar é humana.

- O sistema não altera o formato do fechamento consumido pelo BI (é um contrato externo).
- O sistema não decide os critérios de qualidade: o catálogo oficial reflete a autoridade de auditoria (ver §4).

1.3 Princípio central: a esteira binária

O princípio que organiza toda a automação é a **esteira binária**: no modo automático, **todo item coletado termina em um de dois estados — auditado ou descartado com motivo registrado**. Nada fica "preso" em um estado intermediário esperando alguém.

Isso tem uma consequência prática importante para o diagnóstico do dia a dia: quando o painel aparece vazio, **não é sinal de falha** — é, quase sempre, o resultado esperado dos filtros de negócio terem barrado as entradas. Cada descarte fica registrado com seu motivo.

2. Termos e definições

Glossário dos termos usados ao longo do documento e na própria interface.

Termo	Significado
Ligação / chamada	Uma gravação de atendimento telefônico, a unidade de trabalho do sistema.
Coleta / sync	Processo automático que busca as gravações do dia anterior na Huawei.
Pipeline D-1	A rotina diária que processa o lote do "dia menos 1" (ontem).
Manifesto	A lista de todas as gravações que a Huawei reporta para um dia.
Filtro de negócio	Regra que descarta uma ligação antes de gastar IA (duração, direção, operador não cadastrado, etc.).
Triagem	Etapa que escolhe, entre as candidatas, as melhores para auditar — manual (auditor) ou assistida por IA.
Classificação	Identificação de setor, alerta e operador de uma ligação.
Alerta	A categoria/motivo de auditoria associada à ligação (define quais critérios se aplicam).
Critério	Cada item objetivo avaliado na ligação (ex.: "confirmou os dados do cliente").
Setor	A operação/equipe à qual a ligação pertence (ex.: Fênix, UTI, Central).
Auditoria	O resultado da avaliação: nota, resumo e feedback por critério.
Zeragem	Quando uma falha grave zera a nota da auditoria, independentemente dos demais critérios.
Arquivos Salvos	A área onde toda auditoria (automática ou manual) aguarda a revisão humana.
Gate humano	O ponto obrigatório em que um auditor revisa a auditoria antes de enviá-la ao supervisor.
Cota	Limite de 2 auditorias por operador por mês no envio ao supervisor.
Esteira binária	O princípio de que todo item automático termina auditado ou descartado (ver §1.3).
Tombstone	Marca permanente de descarte — a ligação descartada não volta em coletas futuras.
Guardrail	Proteção determinística (não-IA) que impõe uma regra ou um limite.
Kill-switch	Chave que corta imediatamente todo o consumo pago de IA, sem precisar de redeploy.
Fechamento	A consolidação mensal das notas em planilha Excel para o BI.
Role	O papel do usuário no sistema (<code>admin</code> ou <code>supervisor</code>), que define o que ele pode fazer.

3. Visão geral do sistema

3.1 O que o sistema faz, em seis passos

1. **Coleta.** Uma vez por dia, busca as gravações do dia anterior na telefonia Huawei AICC. Também aceita áudio ou PDF por envio manual.
2. **Seleciona.** Aplica filtros de negócio (operador auditável, direção da chamada, duração, cota) e uma triagem assistida por IA que escolhe as melhores candidatas por setor — tudo isso **antes** de gastar IA.

3. **Classifica.** Identifica setor, alerta e operador com GPT-4o, apoiado por guardrails determinísticos. Casos incertos vão para revisão humana em vez de seguir com falsa certeza.
4. **Audita.** Transcreve o áudio (Azure Fast Transcription com seletor de candidatos) e avalia a ligação contra o catálogo oficial de critérios do setor/alerta (12 setores, 71 alertas, 1051 critérios), gerando nota, resumo e feedback por critério.
5. **Submete ao gate humano.** Toda auditoria — automática ou manual — fica em **Arquivos Salvos** para o auditor revisar antes de enviar ao supervisor (a cota de 2 por operador/mês é aplicada no envio).
6. **Fecha o ciclo.** O supervisor aprova ou contesta; contestações passam por revisão técnica; o fechamento mensal consolida as notas na planilha do BI.

3.2 O caminho de uma ligação, do início ao fim

O diagrama abaixo mostra os estágios reais e os status que uma ligação assume. Os nomes são os mesmos usados no código (`backend/core/`) e nas constantes de status (`backend/db/domain_constants.py`).

```
flowchart TD
    CRON["Cron diário (scheduler externo)<br/>POST /api/telefonica/cron/sync"] --> D1["Pipeline D-1<br/>Huawei<br/>(06:00 BRT, com retries)"]
    D1 --> DESC["Descoberta de chamadas<br/>VDN quercalls + manifesto OBS"]
    DESC --> FILT["Filtros nativos (sem custo de IA)<br/>operador, direção, duração, cota"]
    FILT --> TRI["Triagem assistida por IA<br/>até 2 por setor"]
    TRI --> DL["Download da gravação"]
    DL --> FILA["Fila de revisão<br/>status: pending"]
    FILA --> CLS["Classificação GPT-4o<br/>+ guardrails determinísticos"]
    CLS -->|"confiança suficiente"| READY["pronto para auditar"]
    CLS -->|"incerteza / bloqueio"| MANUAL["revisão humana na Triagem"]
    MANUAL -->|"correção manual"| READY
    READY --> ENG["Motor de automação<br/>lotes com teto de tempo/custo"]
    ENG -->|"audita"| AUD["Auditoria criada<br/>vai para Arquivos Salvos"]
    ENG -->|"item não presta"| TOMB["Descarte permanente (tombstone)"]
    AUD -->|"gate humano: auditor revisa e envia<br/>(cota 2/operador/mês)"| PEND["fila do<br/>supervisor"]
    PEND -->|"aprova"| APPR["aprovada"]
    PEND -->|"contesta"| CONT["contestação"]
    CONT --> REV["Revisão técnica"]
    REV --> APPR
    APPR --> FECH["Fechamento mensal<br/>Excel consumido pelo BI"]
```

3.3 Três observações que evitam diagnósticos errados

- **Painel vazio não significa IA quebrada.** Quase sempre, os filtros de negócio barraram as entradas — é regra de negócio, intencional.
- **Auditorias automáticas e manuais se misturam em Arquivos Salvos de propósito.** O gate humano é único; isso é desenho, não defeito.
- **A auditoria manual também aceita documentos** (PDF de chat), além de áudio. O sistema decide o caminho pelo tipo do arquivo enviado.

3.4 A pilha de tecnologia, em uma linha

FastAPI (Python 3.11) + React 19/TypeScript/Vite + PostgreSQL 17 + Azure OpenAI GPT-4o (classificação e avaliação) + Azure Speech Fast Transcription (transcrição) + Huawei AICC (origem das gravações). O sistema roda como um único container.

4. Papéis e responsabilidades

4.1 Perfis de uso

Perfil	Papel no sistema (role)	O que faz
Auditor(a)	<code>admin</code>	Opera a triagem, a auditoria manual e os Arquivos Salvos (o gate humano). Administra critérios, setores, colaboradores e prompts.
Supervisor	<code>supervisor</code>	Tem um portal próprio: aprova ou contesta as auditorias da sua equipe e acompanha as exportações.
Gestores	(sem login)	Recebem relatórios e exportações. A linguagem gerencial está em <code>docs/manual-gestores/</code> .

O papel do usuário (`role`) é o que o sistema usa para liberar ou bloquear cada ação — o detalhe técnico de como isso é verificado está na §8 (Segurança).

4.2 A autoridade de auditoria

O catálogo oficial de critérios reflete o que a **autoridade de auditoria** (a auditora responsável pela operação) determina — é o "gabarito" (ground truth) contra o qual a IA é calibrada. Ajustes de critérios e calibração da IA seguem essa decisão: **o sistema se adapta à auditoria, não o contrário**. É esse princípio que dá legitimidade à nota produzida.

5. Arquitetura e componentes

5.1 Visão de alto nível

O sistema é um **monorepo full stack** servido por um **único container** em produção. Isso costuma surpreender: não há "servidor do frontend" separado do "servidor do backend". O mesmo processo FastAPI:

- expõe a API em `/api/`, e
- entrega o site (o build do React/Vite) em todo o resto das URLs.

A montagem do site dentro da API é literal — está no fim do `main.py`:

Fonte: backend/main.py:483-508

```
python dist_path = os.path.abspath(os.path.join(os.path.dirname(file), "..", "dist")) if
os.path.exists(dist_path): logger.info("Servindo frontend em: %s", dist_path)
```

```
class CacheControlStaticFiles(StaticFiles):
    async def get_response(self, path: str, scope):
        ...
        if response.status_code == 404:
            response = await super().get_response("index.html", scope) # fallback da SPA
        ...
        return response

app.mount("/", CacheControlStaticFiles(directory=dist_path, html=True), name="static")
```

...

O que dá para aprender aqui: quando o navegador pede uma rota que não existe como arquivo (ex.: /auditoria), o servidor devolve o index.html (o "fallback da SPA"), e o React assume o roteamento. Arquivos estáticos com hash no nome (assets/...) recebem cache "para sempre"; o HTML recebe "nunca cachear" — é o que garante que uma nova versão do sistema apareça na hora para o usuário.

A estrutura de pastas do repositório:

```
auditoria/
|-- backend/          # FastAPI (Python 3.11) – a API e toda a lógica
|-- src/              # React 19 + TypeScript + Vite + Tailwind – as telas
|-- tests/            # tests/backend (pytest) + tests/frontend (Node)
|-- scripts/          # diagnósticos pontuais + scripts/migration/
|-- docs/             # documentação técnica (índice em docs/README.md)
|-- logs/versions/    # changelog técnico por versão (x.y.z.md)
|-- rag/sources/       # fontes curadas dos procedimentos (RAG)
|-- Dockerfile        # multi-stage: build do Vite -> Python 3.11 + ffmpeg
```

5.2 Backend, por subsistema

Toda a API é montada juntando "routers" — cada um cobre um domínio. O wiring fica explícito no main.py , e ler essa lista é a forma mais rápida de entender de quantas partes o sistema é feito:

Fonte: backend/main.py:463-480

```
python app.include_router(auth_router) # login e sessão app.include_router(system_router) #
health, configurações dinâmicas app.include_router(saved_files_router) # Arquivos Salvos (gate
humano) app.include_router(audit_router) # auditoria manual
app.include_router(classifier_router) # triagem / classificação
app.include_router(supervisor_router) # portal do supervisor app.include_router(review_router)
# revisão técnica de contestações app.include_router(admin_router) # administração
app.include_router(automation_router) # motor de automação app.include_router(telefonica_router)
# integração Huawei ... # + critérios, setores, prompts, fechamento
```

Dentro de `backend/core/`, a lógica é dividida por assunto:

Subsistema	Onde fica	O que faz
Transcrição	<code>core/transcription*.py</code>	Converte áudio em texto; engine default <code>fast</code> , com cadeia de fallback e um seletor de candidatos.
Classificação	<code>core/classification.py</code> , <code>core/llm_triage.py</code>	Identifica setor/alerta/operador; triagem das candidatas.
Elegibilidade	<code>core/automation_guardrails.py</code>	Fonte única das regras de "esta ligação pode ser auditada?" (usada pelo sync e pela automação).
Avaliação	<code>core/audit_evaluator.py</code> , <code>core/evaluation.py</code>	Compara a ligação com os critérios e calcula a nota (inclui a zeragem).
Automação	<code>core/automation*.py</code>	O motor que audita em lote, com lock, heartbeat e descarte com tombstone.
Huawei	<code>core/huawei*.py</code> , <code>core/huawei/</code>	Descoberta, coleta D-1, sync, cadeia de download.
Custo	<code>core/cost_guard.py</code>	Tetos diários e kill-switch (ver §9).

Decisão de arquitetura que vale memorizar: as regras de elegibilidade têm **uma fonte só** (`AutomationGatekeeper`). O sync e a automação chamam a mesma função — uma regra nunca é duplicada em dois lugares, o que evita que mudem uma e esqueçam a outra.

5.3 Frontend, por feature

As telas são organizadas por domínio em `src/features/<dominio>/`. Cada feature é um conjunto de tela + lógica + chamadas à API:

Feature (src/features/)	Tela / fluxo
classifier/	Triagem (entrada do fluxo)
audit/	Auditoria manual (upload, configuração, resultado)
saved-files/	Arquivos Salvos (o gate humano)
supervisor/	Portal do supervisor
review/	Revisão técnica de contestações
fechamento/	Fechamento mensal
settings/	Configurações operacionais
automacao/	Painel do motor de automação
telefonias/	Sync Huawei (status, disparo manual, diagnósticos)
admin/	Critérios, setores, prompts
colaboradores/	Cadastro de operadores (o campo "ID Huawei" controla o sync)
ai-feedback/	Calibração da IA

5.4 As camadas de dados

Uma regra de organização importante: **o SQL não fica nos routers**. Ele fica em `repositories/` (um arquivo por agregado: `audits`, `telefonias`, `operators`, `configuration`, `auth_users`, ...). Os routers chamam os repositórios; os repositórios falam com o banco. Isso mantém a API limpa e o acesso a dados testável.

O acesso físico ao banco fica em `db/` :

- `db/connection.py` — o pool de conexões (psycopg2), com timeouts e `sslmode=require` para hosts remotos.
- `db/database.py` — a fachada: `init_db()` roda migrations + seeds idempotentes no boot.
- `db/migration_steps/` — a única forma de evoluir o schema (ver §5.6).
- `db/domain_constants.py` — os status canônicos (os nomes de estado usados no fluxo da §3.2).

5.5 O que é legado (não usar como referência)

Item	Situação
<code>hybrid_dual</code> (engine de transcrição)	Descontinuado. Só roda atrás de uma flag de legado; a engine validada e em uso é a <code>fast</code> .
<code>scripts/</code> e <code>backend/scripts/</code>	Diagnósticos pontuais acumulados; nada disso roda em produção.
Restos de Gemini/AssemblyAI no código	Compatibilidade antiga; o caminho validado é 100% Azure.

5.6 Decisões de arquitetura registradas

- O **schema do banco evolui só por** `db/migration_steps/` (um runner aplica os passos em ordem, com commit por passo). Não se edita o schema base para mudanças novas — cria-se um passo de migração.
- **Histórico de mudanças** vive em `logs/versions/x.y.z.md`: uma entrada por versão, com objetivo, arquivos alterados e validação. É o lugar para consultar *por que* um comportamento é como é.

6. Fluxo operacional do dia a dia

Esta seção é o núcleo do documento: como uma ligação sai da telefonia e chega a uma auditoria revisada — e, principalmente, **por que o número auditado por dia costuma ser muito menor do que o total de ligações** (a dúvida mais comum).

6.1 O ciclo diário

O ciclo é disparado de fora, uma vez por dia, por um agendador (hoje o Cloud Scheduler) que chama um endpoint protegido por token:

Fonte: `backend/routers/telefonias_routes/cron_d1.py:53-73`

```
"""python @router.post("/cron/sync") async def cron_sync_d_minus_1(request: Request, body:
Optional[dict] = Body(default=None)): """Gatilho dedicado do scheduler externo para o Coletor D-
1/OBS.
```

```
Agendado 1x/dia. (...) o pipeline `executar_d_minus_1_pipeline` já se
auto-governa – respeita `huawei_d1_enabled` (...), o horário configurado e
a tabela de runs por dia (um lote por data; disparos extras no mesmo dia
não reexecutam lote completo)."""
from routers.automation import _require_cron_token
_require_cron_token(request)          # exige Authorization: Bearer <token>
...
return await sync_d_minus_1(request, body)
```

```
"""
```

O que se aprende aqui: o ciclo **se auto-governa**. Mesmo que o agendador chame duas vezes no mesmo dia, o sistema não reprocessa o lote inteiro — há uma tabela de execuções por data que controla isso. E o "horário de início" configurado na tela é um **portão** (só roda depois dele), não um gatilho — quem dispara é o cron externo.

Depois do disparo, o ciclo tem três grandes momentos:

1. **Coleta (sync):** baixa o manifesto de ontem, aplica os filtros, faz a triagem por setor, baixa os áudios aprovados e classifica.
2. **Automação:** o motor audita os itens prontos, em lotes limitados por tempo e custo, e joga o resultado em Arquivos Salvos.

3. **Gate humano:** o auditor revisa e promove para o supervisor.

6.2 A coleta e os filtros — onde o volume "encolhe"

Quando o manifesto do dia chega, ele costuma trazer **milhares** de gravações. A maioria é descartada por **regras de negócio**, antes de gastar qualquer IA. O primeiro filtro decide se a ligação deve ser pulada:

Fonte: backend/core/huawei_sync.py:1077-1082

```
python skip_reason = _should_skip_call(interacao, operador_resolvido) if skip_reason:
_increment_skip_counter(contadores, skip_reason) _register_direction_skip(call_id, interacao,
operador_resolvido, skip_reason) continue
```

`_should_skip_call` concentra as regras "duras": **operador não cadastrado**, **direção da chamada desconhecida ou de risco** (ex.: receptiva em setor sensível) e **setor não-telefonia**. Logo em seguida vem o filtro de **duração**:

Fonte: backend/core/huawei_sync.py:1115-1124

```
python duration = get_call_duration_seconds(interacao) duration_known =
_call_duration_is_known(interacao) if duration_known and duration < min_sec:
contadores["ignoradas_duracao_minima"] += 1 continue if duration_known and max_sec > 0 and
duration > max_sec: contadores["ignoradas_duracao_maxima"] += 1 continue
```

Ligações curtas demais (silêncio, engano, URA) não têm o que auditar e são cortadas. Esses filtros são **intencionais**: é o que garante que a IA só seja gasta com ligações que valem auditoria.

6.3 O teto por operador — e por que ele foi separado da cota

Havia ainda um terceiro corte, e é o ponto que mudou na versão 1.3.202. Para não auditar muitas ligações do mesmo operador, o sistema limita quantas gravações de um mesmo operador entram por ciclo:

Fonte: backend/core/huawei_sync.py:1084-1106

```
python op_key = (op_name_norm, op_id_norm) current_op_count =
download_count_by_operator.get(op_key, 0)

if cap_op_ciclo > 0 and (op_name_norm or op_id_norm) and current_op_count >= cap_op_ciclo:
contadores["ignoradas_cota_mensal_pre_download"] += 1 database.huawei_sync_log_registrar(
call_id=call_id, status="skipped_quota", failure_reason="teto_download_por_operador_ciclo", ...)
continue
```

O problema que isso resolveu. Antes, esse teto reutilizava a configuração da *cota do supervisor* (`huawei_cota_max_por_operador_mes` , que vale **2**) e ainda pré-carregava as auditorias já feitas no mês. Resultado: o download ficava preso em ~2 ligações por operador, e quem já tinha 2 auditorias no mês nem era baixado. Com poucos operadores no dia, $2 \times N \approx 20$ — era essa a causa de "pedi 400 e veio 20".

A correção foi **desacoplar**: criar um teto próprio do download (`_download_max_por_operador_ciclo` , default **10**, `0` = sem limite), contado fresco a cada ciclo, sem olhar o histórico mensal. A cota de 2/mês do supervisor continua intacta, governando **só o envio** (ver §7.3).

6.4 Quantas baixar: a "Meta" e o teto de segurança

Quantas ligações o ciclo tenta baixar/auditar é a **Meta de auditorias** que você configura na tela. O número de downloads segue a meta, 1 para 1, com um teto de segurança fixo:

Fonte: `backend/core/huawei/automation_config.py:178-221`

```
python HUAWEI_SYNC_DOWNLOAD_HARD_CEILING = 500 # (definido no topo do módulo)

def _effective_download_attempt_limit() -> int: """Quantos downloads tentar por ciclo (clamp [1,
HUAWEI_SYNC_DOWNLOAD_HARD_CEILING]). O numero EFETIVO segue a META de auditorias do
ciclo (downloads = meta, 1:1) (...). Em TODOS os casos o resultado e limitado ao teto fixo (500): a
meta governa o volume, o teto e so a trava de seguranca.""" ... return max(1,
min(HUAWEI_SYNC_DOWNLOAD_HARD_CEILING, _coerce_int(raw_audit_target,
DEFAULT_HUAWEI_SYNC_DOWNLOAD_LIMIT)))
```

Em linguagem simples: **a Meta é o alvo, não a "entrada bruta"**. Se você quer auditar 200, configure 200 — não 1000. Os filtros cortam a lista crua do dia, e não o seu número. O único limite extra é o teto de segurança de **500 por ciclo**: acima disso é preciso mais de um disparo no dia.

6.5 O funil com números reais

Vale ver o funil de um dia real (manifesto de **5.513** ligações) para entender onde o volume vai. Cada linha é um contador real registrado pelo ciclo:

Etapa	Quantas	Tipo
Manifesto do dia	5.513	total
Muito curtas (< 2 min)	2.007	filtro de negócio
Receptiva em setor de risco	1.069	filtro de negócio
Operador não cadastrado	980	filtro de negócio
Teto por operador (era 2)	584	ajustado na v1.3.202
Direção desconhecida	368	filtro de negócio
Setor não-telefonía	285	filtro de negócio
Triagem	90	seleção
Já sincronizadas antes	2	dedup
Sobraram e foram baixadas	~51	—

A leitura: a esmagadora maioria (≈ 4.700) cai em **filtros de negócio legítimos**. Apenas as **584** do "teto por operador" eram um aperto artificial — e é exatamente esse bloco que a v1.3.202 libera ao trocar o teto de 2 para 10.

6.6 A classificação

As ligações que passam pela coleta são classificadas (setor, alerta, operador) com GPT-4o e guardrails. Um detalhe que vale conhecer: alertas têm **apelidos** (aliases), e o sistema sempre resolve o nome canônico antes de consultar os critérios — pela função pública:

Fonte: backend/core/classification.py:511-513

```
python def canonicalize_alert_id(alert_id: str) -> str: """API publica para resolver aliases
(ex.: BAS-POLICIAL -> BAS-PRIORITARIO-POLICIA).""" return _canonicalize_alert_id(alert_id)
```

Quando a classificação fica **incerta**, o item não segue com falsa certeza: vai para **revisão humana** na Triagem. Valores não reconhecidos permanecem `desconhecido` (sem "chute" silencioso), justamente para um humano decidir.

6.7 Endpoints de diagnóstico (operação)

Endpoint	Para quê
GET /api/health	O serviço está vivo?
GET /api/telefonica/sync/diagnostics	Visão geral: sync travado?, lock do banco, e o bloco custo_diario (consumo + tetos + kill-switch).
GET /api/automation/engine/status	Estado do motor (ciclo atual, estágio, último erro).
POST /api/automation/run-now (admin)	Dispara um ciclo manual (depuração).
POST /api/telefonica/sync/reset-lock (admin)	Destrava o sync após uma falha no meio do caminho (também expira sozinho em 30 min).

Diagnóstico nº 1 do dia a dia: "a automação não está auditando nada". Antes de suspeitar da IA, olhe os filtros — operador sem "ID Huawei" cadastrado, direção inválida ou cota do mês atingida barram as entradas, e isso fica registrado com motivo. Painel vazio quase sempre é regra de negócio funcionando, não defeito.

6.8 Agendamento (cron) — como ligar o ciclo diário

O ciclo diário **não começa sozinho**: ele é disparado por um **agendador externo** (scheduler) que chama um endpoint do sistema, uma vez por dia. Esta seção é o passo a passo para configurar esse agendamento.

O que o agendador precisa chamar:

Item	Valor
Endpoint	POST /api/telefonica/cron/sync
Autenticação	Header Authorization: Bearer <CRON_SECRET_TOKEN>
Frequência	1x por dia
Corpo (body)	vazio — o pipeline decide sozinho a data (o dia anterior)

Passo a passo:

1. **Garanta o token.** A variável de ambiente `CRON_SECRET_TOKEN` deve estar definida no servidor; o **mesmo valor** vai no header `Authorization` do agendador. Sem token configurado, o endpoint responde 503/403 (é fail-closed, de propósito).
2. **Crie o job agendado** que faz a chamada HTTP uma vez ao dia (exemplos abaixo).
3. **Confirme que a automação está ligada.** A chave `huawei_d1_enabled` (o toggle no painel de Automação) precisa estar em `true`. Com ela desligada, o pipeline **não roda** mesmo recebendo a chamada do cron.
4. **Ajuste o horário-portão.** O campo "Horário de início" no painel é um **portão** (o ciclo só roda a partir daquele horário), **não** o gatilho. O gatilho é o agendador externo.

Exemplo — chamada HTTP crua (para testar):

```
curl -X POST https://<seu-dominio>/api/telefonica/cron/sync \
-H "Authorization: Bearer $CRON_SECRET_TOKEN"
```

Exemplo — Google Cloud Scheduler (ambiente atual):

```
gcloud scheduler jobs create http auditoria-d1 \
--schedule="0 6 * * *" \           # ajuste para o horário desejado
--uri="https://<seu-dominio>/api/telefonica/cron/sync" \
--http-method=POST \
--headers="Authorization=Bearer <CRON_SECRET_TOKEN>" \
--time-zone="America/Sao_Paulo"
```

(0 6 * * * = todo dia às 06:00 — a expressão segue o padrão cron: minuto hora dia-do-mês mês dia-da-semana .)

Exemplo — Azure (ambiente de destino): usar um **Container Apps Job agendado** ou uma **Logic App** fazendo a mesma chamada HTTP, com o mesmo header `Authorization`. Regra de ouro: deixar **apenas um** agendador ativo, para não duplicar coleta e auditoria.

Comportamento seguro do cron:

- **Idempotente por dia:** disparos extras no mesmo dia **não** reprocessam o lote inteiro — há uma tabela de execuções por data que controla isso.
- **Fail-closed:** token ausente → 503/403; token errado → 403.
- **Auto-governado:** respeita o toggle `huawei_d1_enabled`, o horário-portão e os limites de custo (\$9).

Como verificar que rodou:

Endpoint	Mostra
GET /api/telefonica/sync/d-minus-1/status	As últimas execuções (data, status, tentativas, erro).
GET /api/telefonica/sync/diagnostics	A visão do dia, incluindo o bloco <code>custo_diario</code> .

7. Regras de negócio e critérios

7.1 A cota de envio ao supervisor (2 por operador/mês)

Há um limite de compliance: **no máximo 2 auditorias por operador, por mês, são enviadas ao supervisor**. O ponto sutil — e que costuma ser confundido com o teto de download da §6.3 — é **onde** a cota é aplicada:

Fonte: backend/core/automation_config.py:223-234

```
python def _get_monthly_audit_quota() -> int: """Cota mensal de auditorias por operador
(config huawei_cota_max_por_operador_mes`, default 2).
```

```
Obs.: com `AUTOMATION_AUDIT_IGNORE_MONTHLY_CAP` ON (default), a cota só é
aplicada no ENVIO ao supervisor, não na auditoria automática."""
raw = database.get_config_value("huawei_cota_max_por_operador_mes", "2")
...
return max(1, int(str(raw or "2").strip()))
```

```
...
```

Ou seja: a automação **audita** tudo o que presta (esteira binária), e a cota de 2/mês só decide o que **sobe** para o supervisor. São dois limites diferentes:

Limite	Valor padrão	Onde age	Config
Teto de download por operador	10 por ciclo	Na coleta (§6.3)	huawei_download_max_por_operador_ciclo
Cota mensal por operador	2 por mês	No envio ao supervisor	huawei_cota_max_por_operador_mes

Quando a cota do mês está cheia, o auditor apaga uma auditoria anterior daquele operador para liberar espaço.

7.2 Direção da chamada

O sistema distingue chamada **feita** de chamada **recebida**. A direção vem de uma consulta à central Huawei (VDN), sem custo de IA. Chamadas sem direção definida, ou receptivas em setores de risco, são barradas na coleta (§6.2) — porque a regra de auditoria depende de quem originou a ligação.

7.3 Setores e apelidos

Cada ligação pertence a um **setor** (ex.: Fênix, UTI, Central). Um detalhe de projeto que vale conhecer: o setor tem um **id interno fixo** (do qual as regras dependem) e um **rótulo editável** na tela. O vínculo entre os dois é feito por apelidos (`sector_aliases`), então **renomear o rótulo na tela não quebra nenhuma regra**. Alertas seguem a mesma ideia de apelidos, resolvidos pela `canonicalize_alert_id` (§6.6).

7.4 O catálogo de critérios

A avaliação compara a ligação com o **catálogo oficial: 12 setores, 71 alertas e 1051 critérios**, guardados no banco (`audit_sectors` , `audit_alerts` , `audit_criteria`). Esse catálogo reflete a autoridade de auditoria (§4.2).

Uma proteção importante: se o catálogo do setor/alerta estiver **vazio** no momento da avaliação, o item **volta para a triagem manual** em vez de ser avaliado sem critério. O sistema prefere admitir "não sei avaliar isto" a produzir uma nota sem base.

7.5 A nota e a zeragem

A nota parte de **10** e desconta a cada falha, seguindo o peso de cada critério:

Fonte: backend/core/evaluation.py:106-112

```
```python """Calcula (score_obtido, score_maximo) para um critério seguindo a lógica da planilha BD.
```

A nota final é:  $10.0 - \sum(\text{Peso} + \text{abs}(\text{Deflador}) \text{ para cada falha})$ . Isso significa que para cada critério, o score\_obtido é: - PASS:  $\text{Peso}$  - FAIL:  $\text{Peso} - (\text{Peso} + \text{abs}(\text{Deflador})) = -\text{abs}(\text{Deflador})$ """ ``

Acima disso existe a **zeragem**: certas falhas graves **zeram a auditoria inteira**, independentemente dos outros critérios. Ela é aplicada em **três camadas**, da mais segura para a mais tolerante:

**Fonte:** backend/core/evaluation.py:15-17

```
```python
```

... a zeragem por critério fatal em 3 camadas

(criterionId determinístico → fatal_flags da IA → fallback por substring),

respeitando o fallback legítimo de CPF quando o motorista confirma não ter senha.

```
```
```

Em linguagem direta: (1) primeiro, regras determinísticas por id de critério; (2) depois, os "sinais fatais" que a própria IA apontou; (3) por fim, um fallback por texto. Exemplo clássico: **não solicitar a senha de segurança quando ela é exigida zera a auditoria** — mas com uma exceção legítima já prevista (quando o motorista confirma não ter senha e o CPF é aceito).

---

## 8. Segurança e proteção de dados

### 8.1 Acesso e papéis

- **Login:** cookie de sessão assinado com HMAC-SHA256 (chave `SESSION_SECRET`), senha guardada com bcrypt, validade de 8 horas. A mensagem de erro é sempre a mesma ("Credenciais inválidas"), para não revelar se um usuário existe.
- **Autorização por papel:** cada rota exige o papel certo, por uma "dependência" reutilizável. É assim que uma rota de administração se protege:

**Fonte:** backend/routers/auth.py:325-336

```
python def require_admin(request: Request) -> dict: """Dependencia FastAPI: exige usuario autenticado com role 'admin'. Levanta HTTP 401 se nao autenticado e HTTP 403 se nao for admin.""" user = require_authenticated_user(request) if user["role"] != "admin": raise HTTPException(status_code=status.HTTP_403_FORBIDDEN, detail="Acesso restrito a administradores.") return user
```

- **Limites de tentativa:** o login tem um limitador dedicado (5 tentativas falhas por 5 minutos) e a API tem um limitador global, para conter abuso.

### 8.2 Rede

- **CORS restritivo:** em produção, o sistema **recusa iniciar** se as origens permitidas forem `*` — elas têm de ser explícitas.
- **Cabeçalhos de segurança** em toda resposta: `X-Content-Type-Options: nosniff`, `X-Frame-Options: DENY`, `Referrer-Policy: no-referrer`, HSTS em produção, entre outros.
- **Endpoints de cron** protegidos por Bearer token, com comportamento fail-closed (§6.8).

### 8.3 Segredos

Nenhum segredo fica escrito no código — tudo vem de **variáveis de ambiente**. Os arquivos `.env` reais ficam **fora do controle de versão** (apenas `.env.example`, sem valores, é versionado). Em produção, o recomendado é guardar os segredos em um cofre (ex.: Azure Key Vault) e injetá-los por referência.

São **obrigatórias em produção**: `ENVIRONMENT=production`, `SESSION_COOKIE_SECURE=true` e `ALLOWED_ORIGINS` com as origens exatas do frontend.

### 8.4 Proteção de dados (LGPD)

O sistema lida com gravações de atendimento e dados de operadores — informação sensível. Os controles que sustentam a conformidade:

- **Acesso por papel:** só usuários autenticados, e cada ação exige o papel adequado (§8.1).
- **Retenção:** os áudios classificados têm limpeza automática por retenção (30 dias por padrão).
- **Rastreabilidade:** ações relevantes e mudanças de configuração ficam registradas (§10).

## 8.5 O dado de produção é protegido contra a suíte de testes

A suíte de testes **escreve no banco**. Para que ela nunca rode por engano contra o banco de produção, há uma trava:

**Fonte:** `tests/backend/conftest.py:91-96`

```
python if "ep-aged-river" in db_url and os.getenv("ALLOW_TESTS_ON_PROD_DB") != "1": raise
pytest.UsageError("Suite BLOQUEADA: DATABASE_URL aponta para o banco de PRODUCAO (ep-aged-
river). " "Testes escrevem no banco e poluiriam producao. Use um banco de teste (...).")
```

A regra prática: **os testes rodam sempre contra um banco de teste, nunca contra produção.**

## 9. Custos e contingência

### 9.1 Onde há custo

O sistema usa serviços pagos de IA: **GPT-4o** (classificação e avaliação) e **Azure Speech** (transcrição). Uma auditoria automática típica custa três chamadas: 1 transcrição + 1 classificação + 1 avaliação.

### 9.2 Proteções de custo (guardrails)

Para garantir um teto de gasto **previsível**, o sistema tem proteções estruturais, independentes de qualquer configuração de cadência ou engine:

1. **Teto diário de chamadas de IA** — padrão **1500** por dia. Ao atingir, o pipeline para de pegar itens novos; nada é descartado, a fila espera o dia seguinte.
2. **Teto diário de auditorias** — padrão **200** por dia.
3. **Kill-switch** — corta todo o consumo pago **na hora, sem precisar de redeploy**:

**Fonte:** `backend/core/cost_guard.py:108-122`

```
python def kill_switch_active() -> bool: """Kill-switch de custo: env COST_KILL_SWITCH ou
config cost_kill_switch. A via por banco permite cortar o consumo pago em producao com um
simples UPDATE em `configuracoes`, sem redeploy (...).""" if (os.getenv("COST_KILL_SWITCH") or
"").strip().lower() in {"1", "true", "yes", "on"}: return True ... raw =
database.get_config_value("cost_kill_switch", "") return str(raw).strip().lower() in {"1",
"true", "yes", "on"}
```

Para acionar o kill-switch em uma emergência, basta um comando no banco:

```
UPDATE configuracoes SET valor='true' WHERE chave='cost_kill_switch';
```

Reverter é o mesmo comando com `valor='false'`.

**Princípio:** o bloqueio por custo **nunca descarta um item** — ele apenas adia para o dia seguinte. E a verificação é **fail-open**: se o banco estiver indisponível, a operação não trava (é proteção financeira, não controle de acesso).

## 9.3 Contingência

| Situação                            | O que fazer                                                                  | Referência                               |
|-------------------------------------|------------------------------------------------------------------------------|------------------------------------------|
| Sync travado após uma falha         | <code>POST /api/telefoniasync/reset-lock</code> (ou esperar o TTL de 30 min) | <code>docs/05-operacao-runbook.md</code> |
| Migrar o banco de dados             | Procedimento de dump → restore → validação                                   | <code>docs/10-migracao-banco.md</code>   |
| Subir o sistema em outra plataforma | Requisitos de container e variáveis                                          | <code>docs/11-deploy.md</code>           |
| Conter gasto imediatamente          | Kill-switch (§9.2)                                                           | —                                        |

## 10. Indicadores e rastreabilidade

### 10.1 O que é medido

O consumo diário de IA é contabilizado (tabela `api_usage_daily`) e exposto no bloco `custo_diario` do diagnóstico ( `GET /api/telefoniasync/diagnostics` ): quantas chamadas, contra os tetos, e o motivo de um eventual bloqueio.

### 10.2 Rastreabilidade (trilha de auditoria do próprio sistema)

| Evento                                   | Onde fica registrado                                                      |
|------------------------------------------|---------------------------------------------------------------------------|
| Cada ligação descartada na coleta        | <code>huawei_sync_logs</code> , com o status e o motivo (tombstone)       |
| Cada execução do ciclo diário            | <code>huawei_d_minus_1_runs</code> (data, status, tentativas, contadores) |
| Cada mudança de configuração             | Log de auditoria das configurações dinâmicas                              |
| Cada mudança de comportamento do sistema | <code>logs/versions/x.y.z.md</code> (uma entrada por versão)              |

Essa trilha é o que permite responder, depois, **por que** uma ligação não foi auditada ou **quando** uma regra mudou — a base de qualquer auditoria do processo.

## 10.3 Onde acompanhar no dia a dia

| Quero ver...                        | Endpoint / tela                                                        |
|-------------------------------------|------------------------------------------------------------------------|
| Se o serviço está no ar             | GET /api/health                                                        |
| A situação do sync e o custo do dia | GET /api/telefonica/sync/diagnostics                                   |
| O estado do motor de automação      | GET /api/automation/engine/status                                      |
| As últimas coletas diárias          | GET /api/telefonica/sync/d-minus-1/status                              |
| A produção de auditorias do mês     | Painel <b>Automação</b> ("Auditorias do mês") e <b>Arquivos Salvos</b> |

## 11. Configurações do sistema

As configurações operacionais ficam no painel **Automação** → **Configurações**. Elas são do auditor/operação — este documento apenas explica o que cada uma faz. A tabela abaixo segue **exatamente os rótulos que aparecem na tela**.

| Rótulo na tela                       | O que faz                                                                                                                 | Padrão | Chave no banco                         |
|--------------------------------------|---------------------------------------------------------------------------------------------------------------------------|--------|----------------------------------------|
| <b>Automações</b><br>(horário)       | Horário-portão: o ciclo só roda a partir dele. É <b>somente leitura</b> — o disparo real vem do agendador (§6.8).         | —      | huawei_d1_horario_execucao             |
| <b>Dias para trás</b>                | Quantos dias anteriores buscar na coleta.                                                                                 | 1      | huawei_d1_lookback_dias                |
| <b>Cota mensal por operador</b>      | Máximo de auditorias por operador <b>enviadas ao supervisor</b> no mês (§7.1).                                            | 2      | huawei_cota_max_por_operador_mes       |
| <b>Meta de auditorias</b>            | Quantas ligações <b>baixar e auditar por ciclo</b> . É o alvo, 1:1 com os downloads, com teto de segurança de 500 (§6.4). | —      | automacao_audit_target_count           |
| <b>Máx. por operador no download</b> | Ligações do mesmo operador por ciclo ( 0 = sem limite). <b>Não</b> é a cota do supervisor (§6.3).                         | 10     | huawei_download_max_por_operador_ciclo |
| <b>Número de tentativas</b>          | Quantas vezes tenta baixar se falhar (1 a 20).                                                                            | —      | huawei_d1_max_retries                  |
| <b>Espera entre tentativas</b>       | Tempo mínimo antes de tentar de novo.                                                                                     | —      | huawei_d1_retry_intervalo_minutos      |

### 11.1 As duas configurações que controlam o volume

Vale reforçar, porque é a dúvida mais comum (e foi o ajuste da versão 1.3.202):



- **"Meta de auditorias"** é **quanto você quer auditar** no ciclo. Quer 200, ponha 200 — não 1000. Os filtros cortam a lista crua do dia, não o seu número.
- **"Máx. por operador no download"** garante variedade: evita que um único operador ocupe todas as vagas do ciclo. O padrão 10 substituiu o antigo aperto de 2, que prendia o volume.
- A **"Cota mensal por operador" (2)** é coisa diferente das duas acima: ela age **só na hora de enviar** ao supervisor, não na coleta nem na auditoria.

### 11.2 Referência completa de variáveis

A lista completa de variáveis de ambiente (com a marca `[CUST0]` nas que afetam gasto) está sempre atualizada em `backend/.env.example`, e explicada em `docs/04-variaveis-de-ambiente.md`.

## 12. Referências

| Tema                           | Documento                                                                         |
|--------------------------------|-----------------------------------------------------------------------------------|
| Índice da documentação técnica | <code>docs/README.md</code>                                                       |
| Visão de negócio               | <code>docs/01-visao-geral.md</code>                                               |
| Mapa do código                 | <code>docs/02-arquitetura.md</code>                                               |
| Schema do banco de dados       | <code>docs/03-banco-de-dados.md</code>                                            |
| Variáveis de ambiente          | <code>docs/04-variaveis-de-ambiente.md</code> · <code>backend/.env.example</code> |
| Operação e diagnóstico         | <code>docs/05-operacao-runbook.md</code>                                          |
| Integração Huawei              | <code>docs/06-integracao-huawei.md</code>                                         |
| Custos e proteções             | <code>docs/07-custos-e-guardrails.md</code>                                       |
| Segurança                      | <code>docs/08-seguranca.md</code>                                                 |
| Testes                         | <code>docs/09-testes.md</code>                                                    |
| Migração do banco              | <code>docs/10-migracao-banco.md</code>                                            |
| Deploy / plataforma            | <code>docs/11-deploy.md</code>                                                    |
| Checklist de handover          | <code>docs/12-checklist-handover.md</code>                                        |
| Guia do código (para devs)     | <code>docs/13-guia-do-codigo.md</code>                                            |
| Manual gerencial               | <code>docs/manual-gestores/</code>                                                |
| Histórico de mudanças          | <code>logs/versions/x.y.z.md</code>                                               |

## Anexo A — Histórico de versões

O histórico técnico completo de cada mudança do sistema vive em `logs/versions/x.y.z.md` — uma entrada por versão, com objetivo, arquivos alterados, validação e pendências. É a fonte para entender **por que** o sistema se comporta de determinada forma hoje.

Convenção do número de versão (`x.y.z`):

- `z` (patch) — ajuste pequeno;
- `y` (minor) — bloco funcional novo;
- `x` (major) — quebra de compatibilidade.

Versão do sistema documentada: **1.3.203**. A mudança de volume mais recente relevante aqui é a **1.3.202** (desacoplamento do teto de download por operador da cota do supervisor — detalhada em §6.3, §7.1 e §11.1).

## Anexo B — Guia das telas (interface)

Os esboços abaixo são **fiéis ao código** — os rótulos, abas e botões são os que aparecem de verdade na tela (extraídos dos componentes React). Cada esboço reserva espaço para o **print real** correspondente, a ser inserido em `docs/manual-sistema/imagens/`.

### B.1 Triage — a porta de entrada (rota `/classifier`)

É onde o fluxo começa: o auditor sobe áudios avulsos, a IA identifica setor/alerta/operador, e cada linha pode ser corrigida, baixada ou enviada à auditoria. A tela também embute a fila de gravações retidas pelo sync Huawei.

```
+-- Triage / Classificacao de Arquivos -----+
| [instrucoes do modulo] |
| |
| +-- Enviar audios -----+ |
| | arraste os arquivos aqui [Classificar] (progresso) | |
| +-----+ |
| |
| Resultados (uma linha por audio): |
| +-----+ |
| | [play] arquivo.wav [Setor v] [Alerta v] Operador | |
| | [editar] [baixar] [Auditar] [excluir] | |
| +-----+ |
| |
| +-- Fila de gravacoes retidas (sync Huawei) -----+ |
| | (RemoteTriageQueue: itens vindos da coleta) | |
| +-----+ |
+-----+
```

[ print real: tela de Triage ]

O que cada controle faz:

- **Classificar** — a IA identifica setor, alerta e operador de cada áudio.
- **editar** — corrige, na própria linha, o setor, o alerta, o operador (nome/matrícula), o supervisor e a escala.
- **baixar** — salva o áudio já com o nome classificado.
- **Auditar** — abre o modal de operador e injeta o arquivo no fluxo de auditoria manual (não chama a IA aqui; só prepara).
- **Fila de retidos** — as gravações que o sync trouxe e que aguardam triagem.

**B.2 Auditoria manual — três passos (rota /audit )**

A auditoria manual é guiada por um trilha de três passos, justamente para reduzir erro operacional. Aceita **áudio** ou **documento (PDF)**.

```
+-- Fluxo de Auditoria • Pipeline de ligacao -----+
| [Audio] [Setor] [Alerta] <- selos de contexto |
| |
| (Passo 1) (Passo 2) (Passo 3) |
| CONTEXTO ARQUIVO REVISAO |
| setor, alerta e envie o audio edite, exporte e |
| operador ou o PDF publique o resultado |
+-----+
| v Passo 1 | v Passo 2 | v Passo 3 |
+-- Contexto -----+ +-- Arquivo -----+ +-- Revisao -----+
Setor [v]		arraste o audio		Nota: 8,5 / 10
Alerta [v]		ou PDF aqui		[grafico de nota]
Operador [____]		[Enviar]		Transcricao
[Iniciar]				Critérios avaliados
+-----+ +-----+ +-----+				
	[Editar][Exportar]			
	[Enviar ao superv.]			
+-----+ +-----+ +-----+
```

[ print real: tela de Auditoria manual ]

- **Passo 1 — Contexto:** define setor, alerta e operador.
- **Passo 2 — Arquivo:** envia o áudio (ou o PDF, para auditoria documental).
- **Passo 3 — Revisão:** mostra a nota (com gráfico), a transcrição e o feedback por critério; permite editar, exportar (PDF) e publicar o resultado.

**B.3 Arquivos Salvos — o gate humano (rota /salvos )**

Depois da auditoria (automática ou manual), o resultado cai **aqui** antes de ir ao supervisor. Automáticas e manuais aparecem **misturadas de propósito**: este é o ponto único de revisão humana.

```

+-- Arquivos Salvos -----+
| [instrucoes do modulo] [buscar...] |
|
+-----+
| Auditoria · Operador · Setor · Alerta · Nota 7,0 |
| origem: [automacao] status: aguardando envio |
| [ver] [editar] [PDF] [Enviar ao superv.] [excluir] |
+-----+
| Transcricao · Operador · Setor ... |
+-----+

```

#### [ print real: tela de Arquivos Salvos ]

- **ver / editar** — abre o detalhe (carregado sob demanda); a edição estruturada recalcula a nota replicando as regras de zeragem.
- **PDF** — exporta o relatório da auditoria.
- **Enviar ao supervisor** — promove a auditoria para a fila do supervisor. É **aqui** que a cota de 2/operador/mês é checada (se cheia, o sistema avisa e permite forçar apagando uma anterior).
- **excluir** — remove o registro (descarta a auditoria vinculada).
- A **origem** (manual/automação) aparece como um selo em cada item.

## B.4 Automação — o painel do ciclo (rota /automacao)

Onde se liga, configura e acompanha o ciclo automático.

```

+-- Automacao de auditorias -----+
| [instrucoes: defina a meta · ligue/pause · roda 1x/dia] |
|
+-- Controle -----+
| Esteira: [LIGADA] [Rodar agora] |
+-----+
+-- Em execucao (quando rodando) -----+
| baixando... · classificando... · auditando... |
+-----+
+-- Configuracoes -----+
| Dias para tras · Cota mensal · Meta de auditorias · |
| Max. por operador no download · Tentativas · Espera |
+-----+
+-- Auditorias do mes -----+
| lista · [abrir em Arquivos] |
+-----+

```

#### [ print real: tela de Automação ]

- **Esteira LIGADA/PAUSADA** — o interruptor geral do ciclo automático.
- **Rodar agora** — dispara um ciclo manual (best-effort, para conferência).
- **Em execução** — mostra o progresso real: baixando, classificando, auditando.
- **Configurações** — os campos detalhados na §11 (inclusive a Meta e o "Máx. por operador no download").
- **Auditorias do mês** — a produção do ciclo, com atalho para abrir em Arquivos Salvos.

## B.5 Colaboradores — o cadastro que controla o sync (rota `/colaboradores`)

O cadastro de operadores. É aqui que se define **quem é auditável** e, em especial, o **ID Huawei** — o campo que decide se as ligações de um operador são baixadas pelo sync (§6.7).

```
+-- Colaboradores -----+
| [instrucoes] Status: [TODOS | ATIVO | INATIVO] |
| [+ Novo colaborador] |
| +-----+
	Nome · Supervisor · Setor · Escala · Status · Auditavel
	Matricula · ID Huawei · ...
	[editar] [ativar/desativar] [excluir]
+-----+	
+-----+
```

### [ print real: tela de Colaboradores ]

- **Filtro de status** — TODOS / ATIVO / INATIVO.
- **+ Novo colaborador** — abre o formulário (nome, supervisor, setor, escala, auditável, matrícula e os IDs de telefonia).
- **Auditável** — marca se o operador entra ou não na auditoria.
- **ID Huawei** — o campo crítico: **sem ele preenchido, o sync não baixa as ligações daquele operador** (é a causa nº 1 de "operador sumido" da coleta).
- **editar / ativar-desativar / excluir** — manutenção do cadastro.

---

Fim do documento. Para inserir os prints reais, salve cada imagem em `docs/manual-sistema/imagens/` e troque o marcador `[ print real: ... ]` da seção correspondente pela referência da imagem.